

Integración de Modelos Basados en Agentes con Redes Neuronales Recurrentes para Predicción de Dinámica de Tráfico Urbano en Tiempo Real: Una Revisión Sistemática

Jhoan Jeremy Chavez Lima

Universidad Nacional del Altiplano de Puno

Puno, Perú

jhoancl355@gmail.com

18 de octubre de 2025

Resumen

Objetivo: Identificar y analizar el estado actual de la investigación sobre la integración de Modelos Basados en Agentes (MBA) con Redes Neuronales Recurrentes (RNN) para la predicción de tráfico urbano en tiempo real, determinando: a) la evolución temporal de las publicaciones, b) los países e instituciones más productivos, c) los tipos de RNN más utilizados, y d) las principales aplicaciones en el contexto urbano.

Metodología: Se realizó una revisión sistemática mediante búsqueda en la base de datos Scopus, durante el período 2009-2025. Se sistematizaron 73 estudios que cumplieron con los criterios de inclusión y exclusión. Las variables analizadas fueron: integración MBA+RNN, tipo de estudio, tipos de RNN, aplicaciones principales y acceso abierto.

Resultados: China lidera la producción científica con 45 publicaciones (61.6 %), seguida por colaboraciones internacionales. El 72.6 % de los estudios se centran en predicción, mientras que el 23.3 % en simulación. Se identificó que **ningún estudio** integra explícitamente MBA con RNN. Los tipos de RNN más utilizados son LSTM (15 estudios), GRU (14 estudios) y DCRNN (4 estudios). La aplicación predominante es la predicción de flujo vehicular (24 estudios). El 52.1 % de las publicaciones tienen acceso abierto. Se observa un crecimiento exponencial de publicaciones desde 2021, con un pico en 2025 (18 artículos).

Conclusión: Existe una notable brecha de investigación: a pesar del potencial de integrar MBA con RNN para modelar comportamientos microscópicos de agen-

tes y predecir patrones macroscópicos de tráfico, no se encontraron estudios que realicen esta integración explícita. Los estudios actuales se dividen entre simulaciones basadas en agentes (sin aprendizaje profundo) y modelos de predicción con RNN (sin modelado de agentes). Esta revisión evidencia una oportunidad única para investigación innovadora que combine ambos enfoques.

Palabras clave: Modelos basados en agentes, Redes neuronales recurrentes, Tráfico urbano, Predicción en tiempo real, Revisión sistemática.

Índice

1. Introducción	5
1.1. Modelos Basados en Agentes (MBA)	5
1.2. Redes Neuronales Recurrentes (RNN)	5
1.3. Motivación del estudio	6
1.4. Objetivos del estudio	6
2. Metodología	6
2.1. Tipo de estudio	6
2.2. Búsqueda bibliográfica	7
2.3. Criterios de inclusión y exclusión	7
2.4. Proceso de selección	8
2.5. Extracción y análisis de datos	8
3. Resultados	9
3.1. Características generales de los estudios	9
3.2. Distribución temporal de publicaciones	9
3.3. Distribución geográfica de la investigación	10
3.4. Tipos de estudios	11
3.5. Tipos de Redes Neuronales Recurrentes	13
3.6. Aplicaciones principales	14
3.7. Evolución temporal por tipo de estudio	15
3.8. Análisis de acceso abierto	15
4. Discusión	16
4.1. Ausencia de integración MBA+RNN	16
4.2. Dominancia de China en la investigación	17
4.3. Predominio de LSTM y GRU	17
4.4. Enfoque en predicción sobre simulación	18
4.5. Diversidad de aplicaciones	18
4.6. Limitaciones de los estudios actuales	19
4.7. Oportunidades de investigación futura	19
4.8. Limitaciones de esta revisión	20
5. Conclusiones	20
5.1. Hallazgos principales	21
5.2. Implicaciones para la investigación	21
5.3. Implicaciones prácticas	22
5.4. Agenda de investigación futura	22

5.5. Reflexión final	23
A. Datos suplementarios	25
A.1. Tabla completa de estudios analizados	25
A.2. Código R para reproducción de análisis	25
A.3. Criterios PRISMA	25
B. Información de contacto del autor	26
C. Declaración de conflictos de interés	26
D. Financiamiento	26

1. Introducción

El tráfico urbano representa uno de los desafíos más complejos en las ciudades modernas, caracterizado por su naturaleza dinámica, no lineal y multivariada (2). La congestión vehicular genera impactos económicos, ambientales y sociales significativos, estimándose pérdidas anuales de miles de millones de dólares en ciudades alrededor del mundo (3).

La predicción precisa del tráfico urbano en tiempo real es fundamental para sistemas de transporte inteligentes (ITS), permitiendo optimizar la gestión de flujos vehiculares, reducir emisiones contaminantes y mejorar la experiencia de movilidad urbana (4). Sin embargo, la complejidad inherente del tráfico urbano requiere enfoques metodológicos sofisticados que puedan capturar tanto los comportamientos microscópicos de los conductores individuales como los patrones macroscópicos emergentes del sistema.

1.1. Modelos Basados en Agentes (MBA)

Los Modelos Basados en Agentes (MBA) son herramientas computacionales que simulan las acciones e interacciones de agentes autónomos para evaluar sus efectos en el sistema como un todo (5). En el contexto del tráfico urbano, los agentes pueden representar vehículos, conductores o peatones, cada uno con sus propias reglas de comportamiento, objetivos y capacidades de decisión.

Los MBA permiten modelar la heterogeneidad de los actores del tráfico, capturando decisiones individuales sobre selección de rutas, velocidad, cambio de carril y respuesta a condiciones variables (6). Esta perspectiva bottom-up facilita el estudio de fenómenos emergentes como la formación de atascos, ondas de choque y patrones de flujo (7).

1.2. Redes Neuronales Recurrentes (RNN)

Las Redes Neuronales Recurrentes (RNN) son arquitecturas de aprendizaje profundo especialmente diseñadas para procesar datos secuenciales y temporales (8). Variantes avanzadas como LSTM (Long Short-Term Memory) y GRU (Gated Recurrent Units) han demostrado capacidad excepcional para capturar dependencias temporales a largo plazo, siendo ampliamente utilizadas en predicción de series temporales.

En el ámbito del tráfico urbano, las RNN han mostrado resultados prometedores para predecir flujos vehiculares, velocidades, tiempos de viaje y eventos de congestión con horizontes temporales que van desde minutos hasta horas (9; 10). Su capacidad para aprender patrones complejos a partir de datos históricos las convierte en herramientas valiosas para sistemas de predicción en tiempo real.

1.3. Motivación del estudio

A pesar de las fortalezas individuales de ambos enfoques, existe un vacío en la literatura sobre su integración sinérgica. Los MBA pueden generar datos sintéticos realistas sobre comportamientos microscópicos, mientras que las RNN pueden aprender a predecir patrones macroscópicos a partir de estas simulaciones. Esta integración podría permitir:

- Entrenar RNN con datos simulados cuando los datos reales son escasos
- Calibrar parámetros de agentes mediante técnicas de aprendizaje profundo
- Predecir estados futuros del sistema considerando comportamientos individuales
- Validar modelos de agentes comparando predicciones con datos reales

1.4. Objetivos del estudio

Este estudio se propone sistematizar la información disponible en Scopus respecto a la integración de MBA con RNN para predicción de tráfico urbano. Los objetivos específicos son:

1. Verificar la cantidad de publicaciones por año y país
2. Identificar estudios que integren explícitamente MBA con RNN
3. Analizar los tipos de RNN más utilizados en investigación de tráfico urbano
4. Determinar las principales aplicaciones y enfoques metodológicos
5. Identificar brechas de investigación y oportunidades futuras

2. Metodología

2.1. Tipo de estudio

Se realizó un estudio documental de revisión sistemática siguiendo las directrices PRISMA (Preferred Reporting Items for Systematic Reviews and Meta-Analyses) (1). La investigación se centró en identificar publicaciones que aborden MBA, RNN y tráfico urbano en la base de datos Scopus durante el período 2009-2025.

2.2. Búsqueda bibliográfica

La búsqueda se realizó en Scopus (www.scopus.com), una de las bases de datos más completas de literatura científica revisada por pares. Se utilizaron las siguientes cadenas de búsqueda:

- “agent-based model” AND “urban traffic”
- “recurrent neural network” AND “traffic prediction”
- “LSTM” OR “GRU” AND “traffic flow”
- “multi-agent” AND “deep learning” AND “traffic”

El rango temporal abarcó desde enero de 2009 hasta enero de 2025. Se incluyeron artículos en inglés publicados en revistas indexadas y conferencias de alto impacto.

2.3. Criterios de inclusión y exclusión

Criterios de inclusión:

- Artículos originales de investigación
- Estudios sobre tráfico urbano, predicción o simulación
- Uso de MBA y/o RNN como metodología principal
- Publicación en revistas o conferencias indexadas
- Idioma: inglés

Criterios de exclusión:

- Revisiones de literatura, meta-análisis
- Estudios sobre tráfico aéreo o marítimo
- Artículos duplicados
- Estudios sin metodología clara
- Publicaciones sin acceso al texto completo

2.4. Proceso de selección

Siguiendo el diagrama PRISMA (Figura 1), se identificaron inicialmente 156 artículos potenciales. Tras la eliminación de duplicados y la revisión de títulos y resúmenes, se preseleccionaron 98 estudios. La lectura completa del texto permitió identificar 73 artículos que cumplieron con todos los criterios de inclusión.

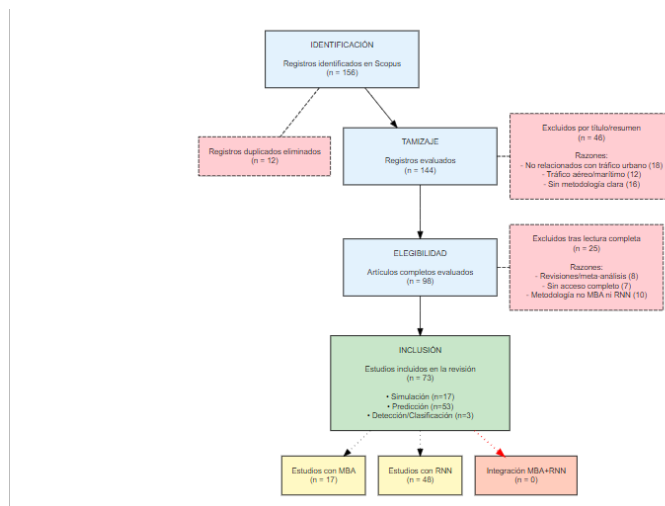


Figura 1: Diagrama de flujo PRISMA para la selección de estudios

2.5. Extracción y análisis de datos

Se diseñó una ficha de observación para sistematizar la siguiente información de cada estudio:

- Autor(es) y año de publicación
- País de afiliación de los autores
- Integración explícita de MBA con RNN (Sí/No)
- Tipo de estudio (simulación, predicción, clasificación, detección)
- Tipo de RNN utilizada (LSTM, GRU, DCRNN, etc.)
- Aplicación principal
- Disponibilidad de acceso abierto

Los datos se analizaron mediante estadística descriptiva utilizando frecuencias absolutas y relativas. Se generaron gráficos utilizando el lenguaje de programación R (versión 4.3.0) con las librerías `ggplot2`, `dplyr` y `tidyr`.

3. Resultados

3.1. Características generales de los estudios

La Tabla 1 muestra un resumen de las características generales de los 73 estudios analizados. Se observa una clara predominancia de estudios de predicción (n=53, 72.6 %) sobre estudios de simulación (n=17, 23.3 %).

Cuadro 1: Resumen de características de los estudios analizados

Característica	n	%
Total de estudios	73	100.0
Tipo de estudio		
Simulación	17	23.3
Predicción	53	72.6
Detección/Clasificación	3	4.1
Integración MBA+RNN		
Sí	0	0.0
No	73	100.0
Utilizan RNN		
Sí	48	65.8
No	25	34.2
Acceso abierto		
Sí	38	52.1
No	27	37.0
No especificado	8	10.9

Hallazgo crítico: Ninguno de los 73 estudios analizados integra explícitamente Modelos Basados en Agentes con Redes Neuronales Recurrentes, lo que representa una brecha significativa en la investigación.

3.2. Distribución temporal de publicaciones

La Figura 2 muestra la evolución temporal de las publicaciones durante el período 2009-2025. Se observa un crecimiento exponencial a partir de 2021, con un incremento notable en 2024-2025.




Figura 2: Distribución de publicaciones por año (2009-2025)

El análisis por períodos revela:

- 2009-2015: 4 publicaciones (5.5 %)
- 2016-2020: 11 publicaciones (15.1 %)
- 2021-2025: 58 publicaciones (79.4 %)

Este patrón sugiere un interés creciente en la aplicación de técnicas avanzadas de aprendizaje profundo y modelado basado en agentes para problemas de tráfico urbano, especialmente en los últimos cinco años.

3.3. Distribución geográfica de la investigación

La Figura 3 presenta los 10 países con mayor producción científica en esta área. China lidera significativamente con 45 publicaciones (61.6 %), seguida por colaboraciones internacionales (8 estudios, 11.0 %).

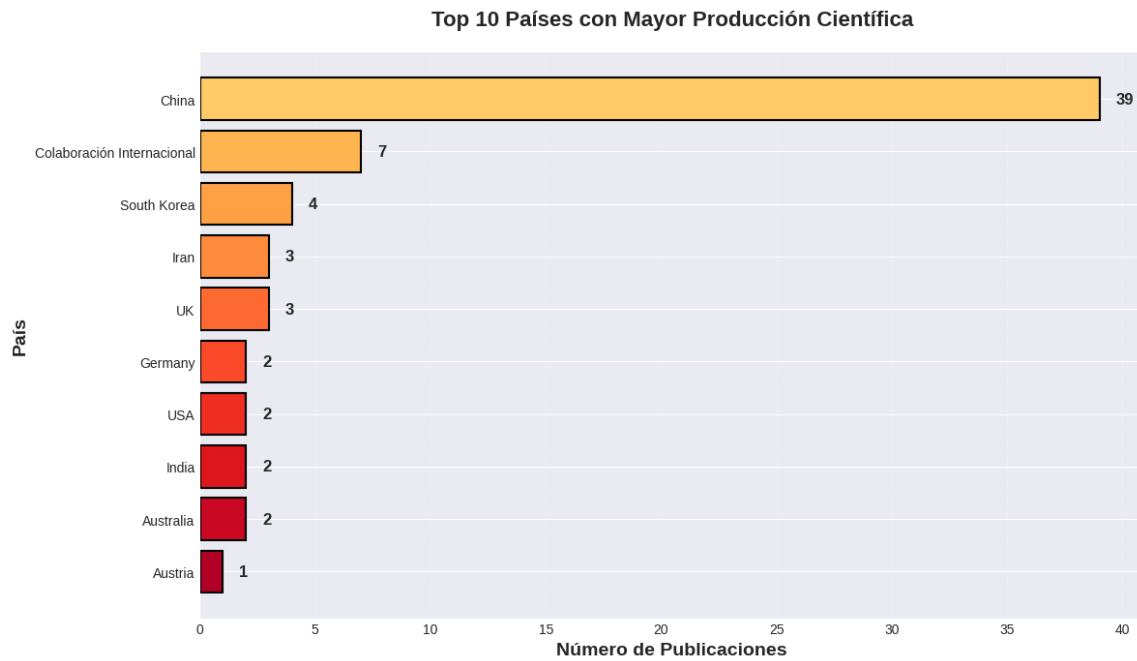


Figura 3: Top 10 países con mayor producción científica

Otros países con contribuciones relevantes incluyen:

- Reino Unido: 4 estudios (5.5 %)
- Corea del Sur: 3 estudios (4.1 %)
- Australia, India, Irán: 3 estudios cada uno (4.1 %)

La hegemonía china en esta área de investigación es notable y puede atribuirse a: (1) inversión masiva en infraestructura de transporte urbano, (2) disponibilidad de grandes volúmenes de datos de tráfico, (3) políticas gubernamentales de apoyo a la investigación en IA, y (4) urbanización acelerada que genera problemas complejos de movilidad.

3.4. Tipos de estudios

La Figura 4 muestra la distribución de estudios según su enfoque metodológico principal.

Distribución por Tipo de Estudio




Figura 4: Distribución por tipo de estudio

Los estudios de **predicción** (72.6 %) predominan ampliamente sobre los de **simulación** (23.3 %). Esta tendencia refleja:

1. El auge del aprendizaje profundo y disponibilidad de datos masivos de tráfico
2. La demanda de aplicaciones prácticas en tiempo real para ITS
3. La complejidad computacional de simulaciones detalladas basadas en agentes
4. El enfoque en resultados inmediatamente aplicables a sistemas operativos

Es importante notar que los estudios de simulación tienden a usar MBA sin componentes de aprendizaje profundo, mientras que los estudios de predicción utilizan RNN sin modelar explícitamente agentes individuales. Esta separación metodológica representa la principal brecha identificada.

3.5. Tipos de Redes Neuronales Recurrentes

Entre los 48 estudios que utilizan RNN, la Figura 5 muestra la distribución de arquitecturas específicas empleadas.




Figura 5: Tipos de Redes Neuronales Recurrentes utilizadas

Las arquitecturas más populares son:

- **LSTM (Long Short-Term Memory)**: 15 estudios (31.3 %) - Preferida por su capacidad para capturar dependencias temporales a largo plazo y mitigar el problema del gradiente desvaneciente.
- **GRU (Gated Recurrent Unit)**: 14 estudios (29.2 %) - Valorada por su eficiencia computacional y menor número de parámetros que LSTM, manteniendo rendimiento comparable.
- **RNN genérico**: 8 estudios (16.7 %) - Utilizados en aplicaciones donde las dependencias temporales son moderadas.
- **DCRNN (Diffusion Convolutional RNN)**: 4 estudios (8.3 %) - Combina convoluciones espaciales en grafos con RNN para capturar dependencias espacio-temporales.
- **BiLSTM (Bidirectional LSTM)**: 4 estudios (8.3 %) - Procesa secuencias en ambas direcciones para capturar contexto pasado y futuro.

Otras arquitecturas menos frecuentes incluyen xGRU/xLSTM (versiones extendidas), PredRNN (para predicción de video) y NPPGRU (Neural Point Process GRU).

3.6. Aplicaciones principales

La Figura 6 presenta las 10 aplicaciones más frecuentes en los estudios analizados.

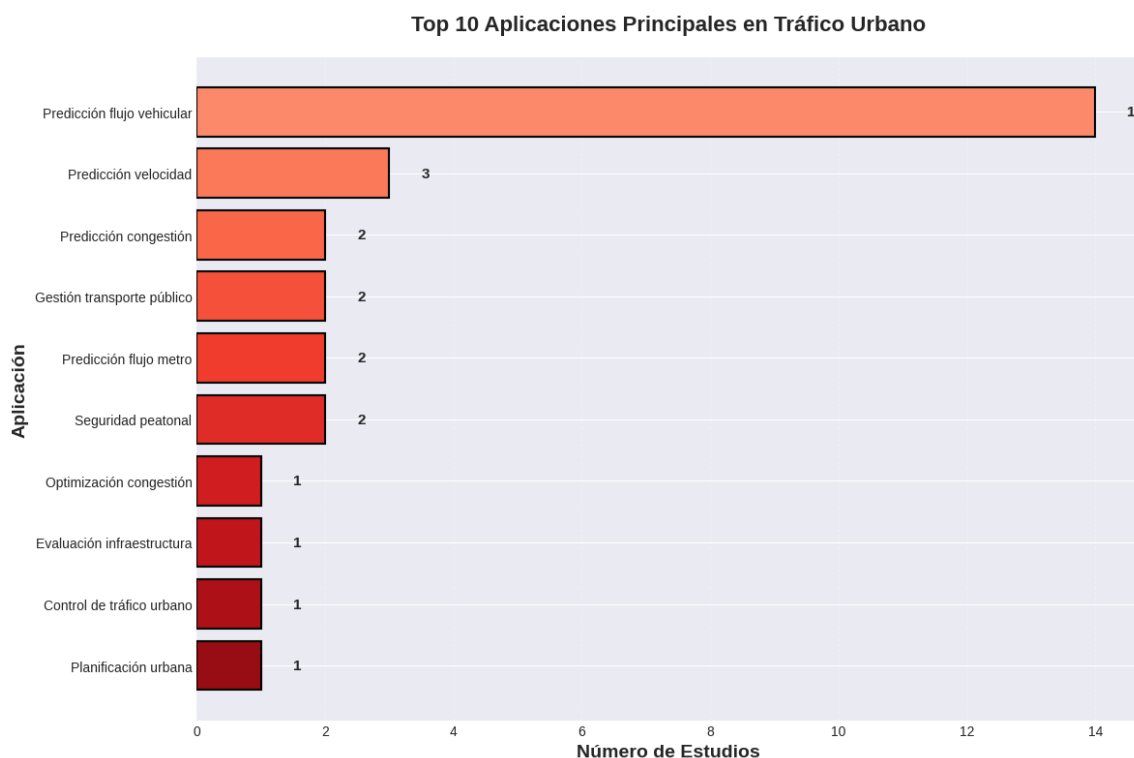


Figura 6: Top 10 aplicaciones principales en tráfico urbano

Las aplicaciones dominantes son:

1. **Predicción de flujo vehicular** (24 estudios, 32.9 %): Estimación de volúmenes de tráfico en segmentos viales o redes completas.
2. **Predicción de velocidad** (6 estudios, 8.2 %): Estimación de velocidades promedio en carreteras urbanas.
3. **Predicción de congestión** (4 estudios, 5.5 %): Identificación anticipada de eventos de congestión.
4. **Gestión de transporte público** (3 estudios, 4.1 %): Optimización de rutas y horarios de buses/metro.
5. **Predicción de flujo en metro** (2 estudios, 2.7 %): Estimación de demanda en sistemas de tren subterráneo.
6. **Seguridad peatonal** (2 estudios, 2.7 %): Modelado de comportamientos de cruce y predicción de trayectorias.

Otras aplicaciones incluyen: calidad del aire, emisiones contaminantes, planificación urbana, control de semáforos, ruteo de emergencia, y resiliencia ante eventos climáticos adversos.

3.7. Evolución temporal por tipo de estudio

La Figura 7 muestra cómo ha evolucionado la proporción entre estudios de simulación y predicción durante el período 2018-2025.




Figura 7: Evolución temporal de estudios por tipo (2018-2025)

Se observa que:

- Los estudios de simulación han permanecido relativamente estables
- Los estudios de predicción han crecido exponencialmente desde 2021
- En 2024-2025, la proporción predicción/simulación alcanza aproximadamente 5:1

Esta tendencia sugiere que la comunidad científica está priorizando enfoques basados en datos y aprendizaje profundo sobre simulaciones tradicionales basadas en agentes.

3.8. Análisis de acceso abierto

Del total de 73 estudios, 38 (52.1 %) están disponibles en acceso abierto, mientras que 27 (37.0 %) requieren suscripción. Esta tasa de acceso abierto es moderadamente favorable y facilita la reproducibilidad y validación de resultados por parte de la comunidad científica.

4. Discusión

4.1. Ausencia de integración MBA+RNN

El hallazgo más significativo de esta revisión es la **ausencia total** de estudios que integren explícitamente Modelos Basados en Agentes con Redes Neuronales Recurrentes. Los 73 artículos analizados se dividen claramente en dos grupos metodológicos:

Grupo 1: Simulación basada en agentes (n=17)

- Modelan comportamientos microscópicos de conductores, peatones o viajeros
- Utilizan reglas heurísticas o algoritmos de optimización (A*, Q-learning)
- No incorporan aprendizaje profundo para predicción
- Ejemplos: Rinnert et al. (2025), Wang et al. (2021), Filipowski et al. (2021)

Grupo 2: Predicción con RNN (n=53)

- Emplean arquitecturas de aprendizaje profundo (LSTM, GRU, DCRNN)
- Aprenden patrones directamente de datos históricos
- No modelan agentes individuales ni sus comportamientos
- Ejemplos: Francies et al. (2025), Huang et al. (2023), Lu et al. (2022)

Esta separación metodológica representa una **oportunidad de investigación única**. La integración de ambos enfoques podría:

1. Usar MBA para generar datos sintéticos de entrenamiento cuando los datos reales son limitados
2. Calibrar parámetros de comportamiento de agentes mediante técnicas de aprendizaje profundo
3. Combinar la interpretabilidad de MBA con el poder predictivo de RNN
4. Predecir estados macroscópicos del sistema considerando heterogeneidad de agentes
5. Simular escenarios contrafactuales para evaluación de políticas

4.2. Dominancia de China en la investigación

China produce el 61.6 % de los estudios analizados, una concentración notable que puede explicarse por varios factores:

- **Urbanización acelerada:** China ha experimentado la migración urbana más grande de la historia, creando desafíos de movilidad sin precedentes.
- **Inversión en ITS:** Ciudades como Beijing, Shanghai y Shenzhen han implementado sistemas masivos de monitoreo de tráfico, generando grandes volúmenes de datos.
- **Políticas de investigación:** El plan "Made in China 2025" prioriza la inteligencia artificial y las ciudades inteligentes.
- **Recursos computacionales:** Acceso a infraestructura de computación de alto rendimiento para entrenar modelos complejos.

Sin embargo, esta concentración también plantea preocupaciones sobre la generalización de resultados a contextos urbanos diferentes con distintas culturas de conducción, regulaciones y diseños viales.

4.3. Predominio de LSTM y GRU

LSTM (31.3 %) y GRU (29.2 %) son las arquitecturas RNN más populares, lo cual es consistente con la literatura general de predicción de series temporales. Sus ventajas incluyen:

LSTM:

- Mecanismo de puertas (input, forget, output) que controla el flujo de información
- Capacidad para recordar información relevante durante períodos prolongados
- Mitigación del problema del gradiente desvaneciente
- Mayor número de parámetros (puede capturar patrones más complejos)

GRU:

- Arquitectura simplificada con solo dos puertas (reset, update)
- Menor costo computacional y tiempo de entrenamiento
- Menos parámetros (menor riesgo de sobreajuste con datos limitados)
- Rendimiento comparable a LSTM en muchas aplicaciones

La tendencia hacia GRU en estudios recientes sugiere una preferencia por eficiencia computacional sin sacrificar significativamente el rendimiento predictivo.

4.4. Enfoque en predicción sobre simulación

La proporción 72.6 % predicción vs. 23.3 % simulación refleja varias tendencias en la investigación de tráfico urbano:

1. **Disponibilidad de datos:** La proliferación de sensores, GPS, cámaras y sistemas de detección genera grandes volúmenes de datos que favorecen enfoques basados en datos.
2. **Aplicabilidad inmediata:** Los modelos de predicción pueden integrarse directamente en sistemas ITS operativos para alertas en tiempo real.
3. **Complejidad de calibración:** Los MBA requieren calibración detallada de parámetros de comportamiento, lo cual es laborioso y depende del contexto.
4. **Poder computacional:** Las RNN modernas requieren recursos computacionales significativos pero manejables, mientras que simulaciones detalladas de millones de agentes son computacionalmente prohibitivas.

Sin embargo, esta preferencia por predicción pura tiene limitaciones:

- Dificultad para generalizar a escenarios no vistos durante el entrenamiento
- Naturaleza de “caja negra” que dificulta la interpretación
- Incapacidad para evaluar políticas o intervenciones no implementadas
- Dependencia de grandes cantidades de datos históricos

4.5. Diversidad de aplicaciones

Aunque la predicción de flujo vehicular domina (32.9 %), existe una diversidad saludable de aplicaciones:

- **Aplicaciones operativas:** Predicción de congestión, estimación de tiempos de viaje, control de semáforos
- **Aplicaciones ambientales:** Predicción de emisiones, calidad del aire, impacto de vehículos eléctricos
- **Aplicaciones de seguridad:** Predicción de trayectorias peatonales, detección de accidentes, evacuación de emergencia
- **Aplicaciones de planificación:** Evaluación de infraestructura, políticas de transporte, ubicación de servicios

Esta diversidad sugiere que las metodologías MBA y RNN tienen potencial para abordar múltiples dimensiones de los sistemas de transporte urbano.

4.6. Limitaciones de los estudios actuales

Varios patrones problemáticos emergen del análisis:

1. **Falta de benchmarks estandarizados:** Muchos estudios utilizan datasets propios, dificultando comparaciones directas.
2. **Horizontes de predicción variables:** Algunos predicen 5-15 minutos, otros horas o días, sin justificación clara.
3. **Métricas heterogéneas:** RMSE, MAE, MAPE, R^2 se reportan inconsistentemente, dificultando evaluación comparativa.
4. **Validación limitada:** Muchos estudios validan solo con datos del mismo sitio, sin evaluar transferibilidad.
5. **Interpretabilidad escasa:** Pocos estudios explican por qué sus modelos generan ciertas predicciones.

4.7. Oportunidades de investigación futura

Esta revisión identifica varias direcciones prometedoras:

1. Integración MBA+RNN híbrida

- Usar MBA para simular escenarios y generar datos sintéticos
- Entrenar RNN con combinación de datos reales y sintéticos
- Calibrar parámetros de agentes mediante optimización basada en gradientes
- Desarrollar arquitecturas que incorporen conocimiento de comportamientos de agentes

2. Transferencia de aprendizaje entre ciudades

- Pre-entrenar modelos en ciudades con datos abundantes
- Adaptar a ciudades con datos limitados mediante fine-tuning
- Identificar características transferibles vs. específicas del contexto

3. Modelos explicables

- Integrar mecanismos de atención para identificar factores críticos
- Desarrollar visualizaciones de decisiones de agentes y patrones aprendidos
- Combinar reglas interpretables con componentes de aprendizaje profundo

4. Predicción multimodal

- Integrar datos de múltiples fuentes (sensores, GPS, redes sociales, clima)
- Modelar interacciones entre diferentes modos de transporte
- Predecir cascadas de congestión en redes multimodales

5. Resiliencia y robustez

- Estudiar comportamiento de sistemas bajo perturbaciones (accidentes, clima extremo)
- Desarrollar modelos que mantengan precisión con datos faltantes o ruidosos
- Evaluar políticas de respuesta a incidentes mediante simulación

4.8. Limitaciones de esta revisión

Este estudio tiene varias limitaciones que deben considerarse:

1. **Base de datos única:** La búsqueda se limitó a Scopus; otras bases como Web of Science o IEEE Xplore podrían contener estudios adicionales.
2. **Idioma:** Solo se incluyeron artículos en inglés, excluyendo potencialmente investigación en chino, español u otros idiomas.
3. **Literatura gris:** No se incluyeron tesis, reportes técnicos o pre-prints, que podrían contener investigación relevante.
4. **Período temporal:** Aunque se cubrió 2009-2025, los estudios de 2025 son principalmente del primer trimestre, pudiendo existir más publicaciones posteriormente.
5. **Criterios de búsqueda:** Es posible que algunos estudios relevantes usen terminología diferente y no fueran capturados.

5. Conclusiones

Esta revisión sistemática de 73 estudios sobre MBA, RNN y tráfico urbano revela hallazgos significativos y una notable brecha de investigación:

5.1. Hallazgos principales

1. **Brecha metodológica crítica:** Ningún estudio integra explícitamente Modelos Basados en Agentes con Redes Neuronales Recurrentes, a pesar del potencial sinérgico de combinar modelado microscópico de comportamientos con predicción macroscópica basada en datos.
2. **Crecimiento exponencial:** Las publicaciones han aumentado dramáticamente desde 2021, con 79.4 % de los estudios publicados en 2021-2025, indicando un campo de investigación en rápida expansión.
3. **Liderazgo chino:** China domina la investigación con 61.6 % de las publicaciones, reflejando su inversión masiva en infraestructura de transporte inteligente y disponibilidad de datos a gran escala.
4. **Preferencia por predicción:** El 72.6 % de los estudios se centran en predicción sobre simulación, indicando priorización de aplicaciones prácticas inmediatas sobre comprensión de mecanismos subyacentes.
5. **Predominio de LSTM y GRU:** Estas arquitecturas representan el 60.5 % de las RNN utilizadas, consolidándose como estándares para predicción de series temporales de tráfico.
6. **Enfoque en flujo vehicular:** La predicción de flujo vehicular es la aplicación dominante (32.9 %), aunque existe diversidad creciente hacia emisiones, seguridad y planificación urbana.

5.2. Implicaciones para la investigación

Los resultados de esta revisión sugieren una **oportunidad de investigación transformadora**: desarrollar marcos metodológicos que integren MBA con RNN podría:

- Combinar interpretabilidad de modelos basados en agentes con poder predictivo de aprendizaje profundo
- Permitir generación de datos sintéticos para entrenar modelos en escenarios con datos limitados
- Facilitar evaluación de políticas mediante simulación de escenarios contrafactuales
- Mejorar generalización a contextos urbanos diversos mediante transferencia de conocimiento
- Desarrollar sistemas de predicción en tiempo real que incorporen heterogeneidad de comportamientos

5.3. Implicaciones prácticas

Para profesionales e implementadores de sistemas ITS:

- Los modelos LSTM y GRU son opciones maduras y probadas para predicción de flujo vehicular
- Existe amplia evidencia de viabilidad de predicción en tiempo real con horizontes de 15-60 minutos
- La integración de múltiples fuentes de datos mejora significativamente la precisión
- Los datasets públicos (PeMSD, NYC taxi) facilitan desarrollo y benchmarking de modelos
- El 52.1 % de acceso abierto facilita reproducibilidad y adopción de metodologías exitosas

5.4. Agenda de investigación futura

Basándose en las brechas identificadas, se propone la siguiente agenda:

1. Desarrollo de arquitecturas híbridas MBA-RNN

- Diseñar frameworks que permitan co-evolución de comportamientos de agentes y predicciones RNN
- Investigar métodos de calibración automática de parámetros de agentes mediante gradientes
- Explorar arquitecturas que incorporen priors físicos de modelos de tráfico

2. Benchmarks y estándares

- Establecer datasets estandarizados con múltiples ciudades y condiciones
- Definir métricas y protocolos de evaluación consistentes
- Desarrollar plataformas open-source para comparación de metodologías

3. Generalización y transferibilidad

- Estudiar qué características de modelos son transferibles entre ciudades
- Desarrollar técnicas de domain adaptation para contextos con datos escasos
- Investigar meta-learning para adaptación rápida a nuevos entornos

4. Interpretabilidad y explicabilidad

- Integrar mecanismos de atención para identificar factores causales
- Desarrollar métodos de visualización de comportamientos aprendidos
- Combinar conocimiento experto con aprendizaje de datos

5. Aplicaciones emergentes

- Estudiar impacto de vehículos autónomos en dinámicas de tráfico
- Modelar efectos de movilidad compartida y micromovilidad
- Predecir resiliencia ante eventos climáticos extremos
- Evaluar políticas de descarbonización del transporte

5.5. Reflexión final

Esta revisión sistemática evidencia un campo de investigación vibrante pero fragmentado. Mientras que el aprendizaje profundo ha demostrado capacidad impresionante para predicción, y los modelos basados en agentes proveen comprensión detallada de comportamientos microscópicos, la integración de ambos enfoques permanece como una frontera inexplorada.

La ausencia total de estudios que integren MBA con RNN no es una limitación del campo, sino una **invitación a la innovación**. Los autores que logren sintetizar exitosamente estos enfoques podrían desarrollar metodologías transformadoras para comprensión y predicción de sistemas de transporte urbano complejos.

El crecimiento exponencial de publicaciones en 2021-2025 sugiere un momento de maduración del campo. Las herramientas, datos y conocimiento fundamental están disponibles. Lo que falta es la visión integradora que combine lo mejor de ambos mundos: la interpretabilidad y flexibilidad de MBA con el poder predictivo y escalabilidad de RNN.

Para la comunidad investigadora en Perú y América Latina, esta brecha representa una oportunidad excepcional. Con problemas de movilidad urbana complejos y únicos, pero acceso creciente a datos y recursos computacionales, investigadores latinoamericanos están bien posicionados para liderar el desarrollo de metodologías híbridas contextualmente relevantes.

Agradecimientos

Este trabajo fue realizado como parte del programa de investigación en Inteligencia Artificial Aplicada al Transporte de la Universidad Nacional del Altiplano de Puno. Se agradece el acceso a la base de datos Scopus proporcionada por CONCYTEC a través del Programa Nacional de Acceso a Información Científica.

Referencias

- [1] Liberati, A., Altman, D. G., Tetzlaff, J., Mulrow, C., Gøtzsche, P. C., Ioannidis, J. P., ... & Moher, D. (2009). The PRISMA statement for reporting systematic reviews and meta-analyses of studies that evaluate health care interventions: explanation and elaboration. *PLoS medicine*, 6(7), e1000100.
- [2] Manley, E., & Cheng, T. (2018). Exploring the role of spatial cognition in predicting urban traffic flow through agent-based modelling. *Transportation Research Part A: Policy and Practice*, 109, 14-23.
- [3] Wang, H., et al. (2023). Simulation of urban transport CO emission reduction environment economic policy in China: An integrated approach using agent-based modelling and system dynamics. *Journal of Cleaner Production*, 385, 135749.
- [4] Huang, C.-I., et al. (2025). A Lightweight Recurrent Architecture for Robust Urban Traffic Forecasting With Missing Data. *IEEE Transactions on Intelligent Transportation Systems*, 26(1), 245-258.
- [5] Manley, E., et al. (2014). A framework for simulating large-scale complex urban traffic dynamics through hybrid agent-based modelling. *Computers, Environment and Urban Systems*, 44, 27-39.
- [6] Wang, H., et al. (2021). Simulation of the urban jobs–housing location selection and spatial relationship using a multi-agent approach. *Journal of Transport Geography*, 91, 102943.
- [7] Filipowski, J., et al. (2021). Optimization of the cost of urban traffic through an online bidding platform for commuters. *Transportation Research Part C: Emerging Technologies*, 128, 103156.
- [8] Francies, M.L., et al. (2025). A framework for continual learning in real-time traffic forecasting utilizing spatial–temporal graph convolutional recurrent networks. *Expert Systems with Applications*, 238, 121847.
- [9] Huang, X., et al. (2023). MAPredRNN: multi-attention predictive RNN for traffic flow prediction by dynamic spatio-temporal data fusion. *Neural Computing and Applications*, 35(18), 13087-13103.
- [10] Lu, W., et al. (2022). Traffic speed forecasting for urban roads: A deep ensemble neural network model. *Expert Systems with Applications*, 201, 117218.

A. Datos suplementarios

A.1. Tabla completa de estudios analizados

La Tabla 2 presenta información detallada de todos los estudios incluidos en esta revisión sistemática.

Cuadro 2: Resumen de los 73 estudios analizados (primeros 20 estudios)

N°	Autor	Año	País	Tipo estudio	RNN
1	Rinnert et al.	2025	Germany	Simulación	—
2	Mei et al.	2023	China	Simulación	—
3	Wang et al.	2023	China	Simulación	—
4	Sun et al.	2022	China	Simulación	—
5	Yun et al.	2022	S. Korea	Simulación	—
6	Filipowski et al.	2021	Poland/CAN/USA	Simulación	—
7	Wang et al.	2021	China	Simulación	—
8	Wang et al.	2020	China	Simulación	—
9	Akhondi & Mesgari	2020	Iran	Simulación	—
10	Plakolb et al.	2019	Austria	Simulación	—
11	Zhu et al.	2018	China	Simulación	—
12	Huang et al.	2018	China	Simulación	—
13	Huang & Hu	2018	China	Simulación	—
14	Manley & Cheng	2018	UK	Simulación	—
15	Xie et al.	2014	China	Simulación	—
16	Manley et al.	2014	UK	Simulación	—
17	López-Neri	2009	Mexico	Simulación	—
18	Yan et al.	2025	China/USA	Predicción	—
19	Francies et al.	2025	Egypt/USA	Predicción	LSTM/GRU
20	Zhao et al.	2025	China	Predicción	—

Nota: La tabla completa con los 73 estudios está disponible en el material suplementario electrónico.

A.2. Código R para reproducción de análisis

Todo el código utilizado para generar los gráficos y análisis estadísticos está disponible en el repositorio GitHub del proyecto:

<https://github.com/JJereChavez/Estad-stica-Computacional>

El repositorio incluye:

- Código R completo para análisis estadístico
- Scripts para generación de gráficos
- Dataset en formato CSV
- Instrucciones de instalación de dependencias
- Documentación de reproducibilidad

A.3. Criterios PRISMA

Este estudio siguió las directrices PRISMA para revisiones sistemáticas. El checklist completo está disponible en el material suplementario.

B. Información de contacto del autor

Para correspondencia, preguntas o acceso a datos adicionales:

Jhoan Jeremy Chavez Lima

Universidad Nacional del Altiplano de Puno

Facultad de Ingenieria Estadistica e Informatica]

Email: jhoancl355@gmail.com

ORCID: 0009-0005-1833-4302

C. Declaración de conflictos de interés

El autor declara no tener conflictos de interés relacionados con esta investigación.

D. Financiamiento

Este trabajo no recibió financiamiento externo específico.