

Universidad Nacional del Altiplano  
Facultad de Ingeniería Estadística e Informática  
**Docente:** Fred Torres Cruz  
**Autor:** Jhoan Jeremy Chavez Lima

# Integración de Enfoques Basados en Modelos con Redes Neuronales Recurrentes para Predicción de la Dinámica del Tráfico Urbano en Tiempo Real

## 1. Introducción

La predicción del tráfico urbano en tiempo real es fundamental para sistemas de transporte inteligentes (ITS) y la gestión eficiente de movilidad urbana [9, 8]. La integración de enfoques basados en modelos físicos (MBA) con redes neuronales recurrentes (RNN) emerge como estrategia prometedora para capturar la complejidad dinámica del flujo vehicular, superando las limitaciones de enfoques puramente teóricos o basados en datos [12, 5].

## 2. Redes Neuronales Recurrentes

Las arquitecturas LSTM y GRU han demostrado superioridad sobre redes feedforward tradicionales en predicción de series temporales por su capacidad de modelar dependencias temporales complejas [10]. Pham et al. [10] lograron un error del 6.374 % en predicción día-adelante. Las variantes bidireccionales (Bi-LSTM, Bi-GRU) proporcionan ventajas adicionales al procesar información en ambas direcciones temporales [9, 1]. Panda et al. [9] proponen una arquitectura híbrida CNN-LSTM-Bi-LSTM que combina extracción de características espaciales con captura de patrones temporales, superando métodos existentes en precisión. Abdellah et al. [1] confirman la superioridad de BiLSTM en predicción de tráfico para vehículos autónomos en redes 5G.

## 3. Modelos Híbridos Físico-Neural

La integración de ecuaciones físicas en RNN mejora significativamente la generalización. Jiang et al. [5] proponen MFD-IDL, integrando el Diagrama Fundamental Macroscópico con deep learning, logrando reducción del 14.3 % en RMSE y 15.3 % en MAE. Chen et al. [2] desarrollan ADNet, incorporando ecuaciones de advección-difusión en LSTM para capturar transporte espacial de información mediante módulos que modelan flujo direccional y propagación de congestión [2]. Würth et al. [12] combinan modelos macroscópicos con procesos gaussianos, representando la discrepancia modelo-datos mientras garantizan consistencia

física. Mahdi y Al Saadi [8] proponen LSTM-GBR para redes SDN, alcanzando precisión de 0.996 y mejorando rendimiento en 39 %.

## 4. Redes Neuronales de Gráficos Espaciotemporales

Las GNN modelan naturalmente dependencias espaciales en redes de tráfico [15, 13]. Zhu et al. [15] presentan ACRGCN, integrando un módulo recurrente con red bayesiana dinámica para capturar topología espaciotemporal intrincada mediante gráficos causales dinámicos. Zhang et al. [13] proponen RostGNN, utilizando GRU para características temporales con umbral iterativo para obtener gráficos dispersos que mejoran robustez y explicabilidad. Ergün [3] optimiza el tiempo de entrenamiento mediante preconditionamiento de matrices de adyacencia, reduciendo significativamente costos computacionales sin sacrificar precisión.

## 5. Enfoques Multiescala e Interpretabilidad

Zhao et al. [14] proponen MSTNN, dividiendo secuencias en parches de diferentes escalas e incorporando redes de Kolmogorov-Arnold (KAN) para mayor interpretabilidad, logrando mejoras del 0.11 %-12.65 %. Ling et al. [6] utilizan descomposición tensorial TTT considerando estabilidad temporal y periodicidad, logrando rendimiento favorable en recuperación de datos con faltantes y predicción futura.

## 6. Aplicaciones y Transferencia de Conocimiento

Guo et al. [4] aplican aprendizaje por refuerzo para estimación de distribución de objetos transformando imágenes a vista aérea sin parámetros de cámara. Ma et al. [7] demuestran transferibilidad entre dominios aplicando TCN con fusión multiescala para predicción de trayectorias marítimas. Sinne y Yanxia [11] muestran aplicabilidad de enfoques multi-agente y control predictivo en gestión energética.

## 7. Conclusión

La integración de modelos físicos con RNN representa un avance significativo en predicción de tráfico urbano. Los modelos híbridos aprovechan la consistencia física mientras capturan patrones complejos mediante deep learning. Las arquitecturas LSTM, GRU y sus variantes bidireccionales, combinadas con GNN, proporcionan marcos robustos para modelar dependencias espaciotemporales. La incorporación explícita de ecuaciones físicas mejora generalización y reduce sobreajuste, mientras que enfoques multiescala y de atención mejoran interpretabilidad. Las consideraciones de implementación, incluyendo optimización computacional y procesamiento distribuido, son cruciales para despliegue efectivo en ITS. La investigación futura debe profundizar en la sinergia entre conocimiento físico y aprendizaje profundo, abordando desafíos de escalabilidad, robustez y explicabilidad en entornos urbanos complejos.

## Referencias

- [1] Abdellah, A. R., Mohamed, M. A., Hassan, H. A., Alsweity, M., Muthanna, A., et al. (2026). Deep Learning-Powered Traffic Prediction for Autonomous Vehicles Using Integrated Fog and Multi-Cloud Services. *Lecture Notes in Computer Science*. DOI: 10.1007/978-3-031-95299-9\_17
- [2] Chen, S., Zhang, B., Liu, D., Li, X., Ye, Y., et al. (2026). Advection-diffusion spatiotemporal recurrent network for regional wind speed prediction. *Pattern Recognition*. DOI: 10.1016/j.patcog.2025.112282
- [3] Ergün, S. (2026). A Study on Optimizing Training Time for Traffic Speed Estimation Using Graph Neural Networks. *Communications in Computer and Information Science*. DOI: 10.1007/978-3-031-93601-2\_14
- [4] Guo, H., Gao, J., & Yuan, Y. (2026). Distantly supervised reinforcement localization for real-world object distribution estimation. *Pattern Recognition*. DOI: 10.1016/j.patcog.2025.112385
- [5] Jiang, R., Wang, S., Liu, B., Zhang, Y., Fan, P., et al. (2026). A novel hybrid macroscopic fundamental diagram-informed deep learning method for lane-level traffic prediction. *Information Fusion*. DOI: 10.1016/j.inffus.2025.103655
- [6] Ling, C., Liu, J., Xie, W., & Duan, Y. (2026). A novel tensor decomposition-based approach for internet traffic data recovery and forecast. *Journal of Computational and Applied Mathematics*. DOI: 10.1016/j.cam.2025.116959
- [7] Ma, Q., Lian, Z., Du, X., Jiang, Y., BahooToroody, A., et al. (2026). A deep learning method to predict ship short-term trajectory for proactive maritime traffic management. *Reliability Engineering and System Safety*. DOI: 10.1016/j.ress.2025.111542
- [8] Mahdi, A., & Al Saadi, A. (2026). Deep Learning-based Smart Traffic Prediction for Enhanced Quality of Service in Software-defined Networking. *International Journal of Engineering, Transactions B: Applications*, 39(3C). DOI: 10.5829/ije.2026.39.03c.14
- [9] Panda, A., Dogra, D. P., & Dey, P. P. (2026). Prediction of Short-Term Traffic Flow Using a Hybrid Architecture. *Communications in Computer and Information Science*. DOI: 10.1007/978-3-031-93697-5\_30
- [10] Pham, T. L. H., Nguyen, V. T. A., Vu, B. H., & Bui, D. T. (2026). Day-Ahead Electricity Demand Forecasting Using LSTM Deep Learning Model. *GMSARN International Journal*.
- [11] Sinne, I. S., & Yanxia, S. (2026). Federated deep MPC-enabled digital twin and multi-agent learning framework for secure and scalable smart nano grid energy management. *Renewable Energy Focus*. DOI: 10.1016/j.ref.2025.100762

- 
- [12] Würth, A., Binois, M., & Goatin, P. (2026). Traffic prediction by combining macroscopic models and Gaussian processes. *Applied Mathematical Modelling*. DOI: 10.1016/j.apm.2025.116397
  - [13] Zhang, Y., Li, Y., Liu, S., & Shang, X. (2026). Robust spatio-temporal graph neural networks with sparse structure learning. *Pattern Recognition*. DOI: 10.1016/j.patcog.2025.112383
  - [14] Zhao, W., Yuan, G., Zhang, Y., Liu, X., Liu, S., et al. (2026). An interpretable and efficient multi-scale spatio-temporal neural network for traffic flow forecasting. *Expert Systems with Applications*. DOI: 10.1016/j.eswa.2025.128961
  - [15] Zhu, J., Yuan, J., Ye, F., Nguyen, T.-T., Wang, R., et al. (2026). Traffic prediction using an active causality recurrent graph convolutional network. *Expert Systems with Applications*. DOI: 10.1016/j.eswa.2025.129506